

Évaluation RAG — Baseline (Phase 8)

Généré automatiquement par `node eval.js`. Les colonnes Pertinence et Fidélité sont à remplir manuellement.

#	Question	Top-1 score	Avg top-3	Tokens (in/out)	Coût (\$)	Latence (ms)	Pertinence (1-5)	Fidélité (1-5)	Notes
1	Quels sont les motifs de discrimination interdits ...	0.8995	0.8628	1491 / 205	0.000211	2353	5	5	Top-3 chunks tous issus de article-droit-travail.txt. Synthèse correcte des motifs avec [Source N].
2	Quelles protections existent pour un salarié qui e...	0.8234	0.8072	1513 / 45	0.000165	1144	5	5	Chunks pertinents. Réponse exacte citant L1132-2 avec [Source 1].
3	Que se passe-t-il si un acte est pris en violation...	0.8275	0.7918	1486 / 13	0.000153	983	4	3	L1132-4 ("est nul") présent dans le chunk mais le LLM répond "je ne trouve pas". Sûr mais réponse manquée.
4	Quels sont les niveaux de stabilité définis dans l...	0.8586	0.8333	1137 / 180	0.000168	1636	5	5	Énumération correcte des 4 niveaux (Deprecated, Experimental, Stable, Legacy).
5	Quels modules Node.js ont le statut Deprecated ?	0.8019	0.7989	1272 / 27	0.000135	870	4	2	⚠ LLM cite "Domain + Query string" mais le corpus indique Query string = (2) Stable. Punycode (0) Deprecated oublié. Mauvaise lecture du tableau.

#	Question	Top-1 score	Avg top-3	Tokens (in/out)	Coût (\$)	Latence (ms)	Pertinence (1-5)	Fidélité (1-5)	Notes
6	Quelle est la différence entre les stades 1.0, 1.1...	0.7533	0.7415	1365 / 13	0.00014	766	3	4	Chunk ne contient pas les définitions 1.0/1.1/1.2 (problème de chunking). Refus correct du LLM.
7	Un salarié juré peut-il être licencié à cause de s...	0.8052	0.7892	1516 / 45	0.000165	1129	5	5	Chunk contient L1132-3-1. Réponse exacte "fonctions de juré" avec [Source 1].
8	Est-ce que le module SQLite de Node.js est stable ...	0.7964	0.7811	1194 / 32	0.000129	943	4	5	Correct : SQLite = (1.2) Release candidate. Bien cité avec [Source 1].
9	Quelle est la capitale de la France ?	0.722	0.7151	1304 / 13	0.000134	1061	1	5	Question adversariale hors corpus. Chunks non pertinents. Refus correct du LLM (pas d'hallucination).
10	Comment configurer un serveur Express avec TypeScr...	0.7161	0.7134	1007 / 13	0.000105	786	1	5	Question adversariale hors corpus. Chunks non pertinents. Refus correct du LLM (pas d'hallucination).

Agrégats

Métrique	Valeur
Questions traitées	10/10
Moyenne Top-1 score	0.8004
Moyenne Avg top-3	0.7834
Tokens totaux (in/out)	13285 / 586

Métrique	Valeur
Coût total	\$0.001505
Latence moyenne / requête	1167ms
Moyenne Pertinence	3.7 / 5
Moyenne Fidélité	4.4 / 5

Légende

- **Top-1 score** : score cosine du chunk le plus pertinent. > 0.8 = très bon match, < 0.5 = hors sujet.
- **Avg top-3** : moyenne des 3 meilleurs scores. Qualité globale du contexte injecté.
- **Pertinence (1-5)** : note humaine — les chunks récupérés sont-ils liés à la question ?
- **Fidélité (1-5)** : note humaine — la réponse reflète-t-elle les sources sans broder/inventer ?

Phase 11 — Audit du retrieval

Généré par `node scripts/audit.js`. Comparaison de variantes contre la baseline (topK=5, chunk=400/overlap=50, threshold=0.7).

Tableau récapitulatif

Variante	Moy Top-1	Moy Avg-3	Coût total	Latence moy	Chunks moy	Δ Top-1
Baseline (topK=5, chunk=400, thr=0.7)	0.8004	0.7834	\$0.001505	1167ms	—	—
topK=1	0.8004	0.8004	\$0.000927	1771ms	1.0	+0.0000
topK=10	0.8005	0.7835	\$0.001257	857ms	3.6	+0.0001
threshold=0.3	0.8004	0.7821	\$0.001285	1191ms	5.0	+0.0000
threshold=0.5	0.8004	0.7820	\$0.001282	926ms	5.0	+0.0000
chunk=200/overlap=50	0.8031	0.7864	\$0.001261	1055ms	4.2	+0.0027
chunk=1000/overlap=200	0.7930	0.7730	\$0.001114	1062ms	3.3	-0.0074

Détail par variante

topK=1

#	Top-1	Avg-3	Chunks	Latence	Δ Top-1
Q1	0.8995	0.8995	1	2032ms	+0.0000
Q2	0.8234	0.8234	1	918ms	+0.0000
Q3	0.8275	0.8275	1	1089ms	+0.0000
Q4	0.8586	0.8586	1	9507ms	+0.0000
Q5	0.8019	0.8019	1	1162ms	+0.0000

#	Top-1	Avg-3	Chunks	Latence	Δ Top-1
Q6	0.7533	0.7533	1	684ms	+0.0000
Q7	0.8052	0.8052	1	923ms	+0.0000
Q8	0.7964	0.7964	1	778ms	+0.0000
Q9	0.722	0.722	1	308ms	+0.0000
Q10	0.7161	0.7161	1	310ms	+0.0000

topK=10

#	Top-1	Avg-3	Chunks	Latence	Δ Top-1
Q1	0.8995	0.8628	4	1638ms	+0.0000
Q2	0.8234	0.8072	3	729ms	+0.0000
Q3	0.8275	0.7918	3	790ms	+0.0000
Q4	0.8586	0.8333	4	1530ms	+0.0000
Q5	0.8021	0.7991	4	980ms	+0.0002
Q6	0.7533	0.7415	7	677ms	+0.0000
Q7	0.8052	0.7892	3	765ms	+0.0000
Q8	0.7964	0.7811	4	950ms	+0.0000
Q9	0.722	0.7151	2	255ms	+0.0000
Q10	0.7166	0.7139	2	253ms	+0.0005

threshold=0.3

#	Top-1	Avg-3	Chunks	Latence	Δ Top-1
Q1	0.8995	0.8628	5	1544ms	+0.0000
Q2	0.824	0.8078	5	2802ms	+0.0006
Q3	0.8275	0.7918	5	954ms	+0.0000
Q4	0.8586	0.8333	5	2253ms	+0.0000
Q5	0.8019	0.7989	5	746ms	+0.0000
Q6	0.7533	0.7415	5	910ms	+0.0000
Q7	0.8052	0.7892	5	894ms	+0.0000
Q8	0.7963	0.781	5	1238ms	-0.0001
Q9	0.722	0.7084	5	267ms	+0.0000
Q10	0.7161	0.7059	5	300ms	+0.0000

threshold=0.5

#	Top-1	Avg-3	Chunks	Latence	Δ Top-1
Q1	0.8995	0.8628	5	2029ms	+0.0000
Q2	0.8234	0.8072	5	829ms	+0.0000
Q3	0.8275	0.7918	5	748ms	+0.0000
Q4	0.8586	0.8333	5	1610ms	+0.0000
Q5	0.8019	0.7989	5	730ms	+0.0000
Q6	0.7533	0.7415	5	648ms	+0.0000
Q7	0.8052	0.7892	5	1062ms	+0.0000
Q8	0.7964	0.7811	5	1027ms	+0.0000
Q9	0.7219	0.7083	5	325ms	-0.0001
Q10	0.7161	0.7059	5	253ms	+0.0000

chunk=200/overlap=50

#	Top-1	Avg-3	Chunks	Latence	Δ Top-1
Q1	0.8995	0.8628	4	2006ms	+0.0000
Q2	0.8254	0.8184	5	865ms	+0.0020
Q3	0.8275	0.7918	3	782ms	+0.0000
Q4	0.8586	0.8333	4	2086ms	+0.0000
Q5	0.8035	0.8004	5	1061ms	+0.0016
Q6	0.7533	0.7415	5	645ms	+0.0000
Q7	0.8158	0.8036	5	1784ms	+0.0106
Q8	0.7964	0.7811	4	847ms	+0.0000
Q9	0.7357	0.7182	5	235ms	+0.0137
Q10	0.7148	0.7131	2	243ms	-0.0013

chunk=1000/overlap=200

#	Top-1	Avg-3	Chunks	Latence	Δ Top-1
Q1	0.8915	0.7912	3	2760ms	-0.0080
Q2	0.8234	0.8072	3	1201ms	+0.0000
Q3	0.8264	0.8186	5	939ms	-0.0011
Q4	0.853	0.8227	4	1577ms	-0.0056
Q5	0.8014	0.7939	4	909ms	-0.0005
Q6	0.7319	0.7272	5	264ms	-0.0214
Q7	0.7871	0.7711	2	963ms	-0.0181

#	Top-1	Avg-3	Chunks	Latence	Δ Top-1
Q8	0.7809	0.7725	3	1526ms	-0.0155
Q9	0.7188	0.7125	2	244ms	-0.0032
Q10	0.7161	0.7134	2	232ms	+0.0000

Régressions identifiées

Régression 1 — Variante `topK=1`, Q1

- Question : "Quels sont les motifs de discrimination interdits par l'article L1132-1 du Code ..."
- Type : contexte_incomplet
- Explication : Avec un seul chunk, la réponse perd en complétude. Baseline utilisait ~3-5 chunks pour couvrir la question.

Régression 2 — Variante `topK=1`, Q2

- Question : "Quelles protections existent pour un salarié qui exerce son droit de grève ?"
- Type : contexte_incomplet
- Explication : Avec un seul chunk, la réponse perd en complétude. Baseline utilisait ~3-5 chunks pour couvrir la question.

Régression 3 — Variante `topK=1`, Q4

- Question : "Quels sont les niveaux de stabilité définis dans la documentation Node.js ?"
- Type : contexte_incomplet
- Explication : Avec un seul chunk, la réponse perd en complétude. Baseline utilisait ~3-5 chunks pour couvrir la question.

Régression 4 — Variante `topK=1`, Q7

- Question : "Un salarié juré peut-il être licencié à cause de ses fonctions de juré ?"
- Type : contexte_incomplet
- Explication : Avec un seul chunk, la réponse perd en complétude. Baseline utilisait ~3-5 chunks pour couvrir la question.

Régression 5 — Variante `topK=1`, Q8

- Question : "Est-ce que le module SQLite de Node.js est stable ?"
- Type : refus_inattendu
- Explication : Baseline répondait bien (pertinence=4/5, fidélité=5/5), la variante refuse malgré le contexte.

Régression 6 — Variante `threshold=0.3`, Q9

- Question : "Quelle est la capitale de la France ?"
- Type : hallucination_risque
- Explication : Question hors corpus (pertinence baseline=1/5) mais variante fournit 5 chunks et le LLM tente de répondre.

Régression 7 — Variante `threshold=0.3`, Q10

- Question : "Comment configurer un serveur Express avec TypeScript ?"
- Type : hallucination_risque

- Explication : Question hors corpus (pertinence baseline=1/5) mais variante fournit 5 chunks et le LLM tente de répondre.

Régression 8 — Variante `threshold=0.5`, Q9

- Question : "Quelle est la capitale de la France ?"
- Type : hallucination_risque
- Explication : Question hors corpus (pertinence baseline=1/5) mais variante fournit 5 chunks et le LLM tente de répondre.

Régression 9 — Variante `threshold=0.5`, Q10

- Question : "Comment configurer un serveur Express avec TypeScript ?"
- Type : hallucination_risque
- Explication : Question hors corpus (pertinence baseline=1/5) mais variante fournit 5 chunks et le LLM tente de répondre.

Régression 10 — Variante `chunk=200/overlap=50`, Q9

- Question : "Quelle est la capitale de la France ?"
- Type : hallucination_risque
- Explication : Question hors corpus (pertinence baseline=1/5) mais variante fournit 5 chunks et le LLM tente de répondre.