

Évaluation RAG — Baseline (Phase 8)

Généré automatiquement par `node eval.js`. Les colonnes Pertinence et Fidélité sont à remplir manuellement.

#	Question	Top-1 score	Avg top-3	Tokens (in/out)	Coût (\$)	Latence (ms)	Pertinence (1-5)	Fidélité (1-5)	Notes
1	Quels sont les motifs de discrimination interdits ...	0.8995	0.8628	1491 / 199	0.000209	2599	5	5	Liste complète et fidèle aux sources
2	Quelles protections existent pour un salarié qui e...	0.8234	0.8072	1513 / 39	0.000163	1119	5	5	Réponse concise et exacte avec citation
3	Quelles sont les conséquences pour un employeur qu...	0.835	0.8022	1483 / 69	0.000169	2145	4	4	Pertinent mais réponse un peu vague sur les sanctions
4	Quels sont les niveaux de stabilité définis dans l...	0.8586	0.8333	1137 / 172	0.000165	2148	5	5	Niveaux 0-3 listés correctement
5	Quels modules Node.js ont le statut Deprecated ?	0.8017	0.7987	1272 / 14	0.000131	821	4	4	Domain identifié, réponse courte mais correcte
6	Quels modules Node.js sont au stade expérimental ?	0.8183	0.8098	1272 / 82	0.000152	1326	4	3	Liste partielle, quelques modules manquants
7	Un salarié juré peut-il être licencié à cause de s...	0.8052	0.7892	1516 / 45	0.000165	1229	5	5	Réponse exacte avec référence source

#	Question	Top-1 score	Avg top-3	Tokens (in/out)	Coût (\$)	Latence (ms)	Pertinence (1-5)	Fidélité (1-5)	Notes
8	Est-ce que le module SQLite de Node.js est stable ...	0.7964	0.7811	1194 / 37	0.000131	919	4	5	Bonne réponse, statut expérimental identifié
9	Quelle est la capitale de la France ?	0.722	0.7151	0 / 0	0	236	1	5	Hors corpus, refus correct (skip-llm)
10	Comment configurer un serveur Express avec TypeScr...	0.7161	0.7134	0 / 0	0	1710	1	5	Hors corpus, refus correct (skip-llm)

Agrégats

Métrique	Valeur
Questions traitées	10/10
Moyenne Top-1 score	0.8076
Moyenne Avg top-3	0.7913
Tokens totaux (in/out)	10878 / 657
Coût total	\$0.001285
Latence moyenne / requête	1425ms
Moyenne Pertinence	3.8/5
Moyenne Fidélité	4.6/5

Légende

- **Top-1 score** : score cosine du chunk le plus pertinent. > 0.8 = très bon match, < 0.5 = hors sujet.
- **Avg top-3** : moyenne des 3 meilleurs scores. Qualité globale du contexte injecté.
- **Pertinence (1-5)** : note humaine — les chunks récupérés sont-ils liés à la question ?
- **Fidélité (1-5)** : note humaine — la réponse reflète-t-elle les sources sans broder/inventer ?

Phase 11 — Audit du retrieval

Généré par `node scripts/audit.js`. Comparaison de variantes contre la baseline (topK=5, chunk=400/overlap=50, threshold=0.7).

Tableau récapitulatif

Variante	Moy Top-1	Moy Avg-3	Coût total	Latence moy	Chunks moy	Δ Top- 1
Baseline (topK=5, chunk=400, thr=0.7)	0.8076	0.7913	\$0.001505	1167ms	—	—
topK=1	0.8076	0.8076	\$0.000982	1149ms	1.0	+0.0000
topK=10	0.8076	0.7913	\$0.001303	953ms	3.3	+0.0000
threshold=0.3	0.8076	0.7899	\$0.001347	900ms	5.0	+0.0000
threshold=0.5	0.8076	0.7899	\$0.001347	869ms	5.0	+0.0000

Détail par variante

topK=1

#	Top-1	Avg-3	Chunks	Latence	Δ Top-1
Q1	0.8995	0.8995	1	3065ms	+0.0000
Q2	0.8234	0.8234	1	775ms	+0.0000
Q3	0.8347	0.8347	1	668ms	-0.0003
Q4	0.8586	0.8586	1	2602ms	+0.0000
Q5	0.8019	0.8019	1	818ms	+0.0002
Q6	0.8183	0.8183	1	1025ms	+0.0000
Q7	0.8052	0.8052	1	916ms	+0.0000
Q8	0.7964	0.7964	1	717ms	+0.0000
Q9	0.722	0.722	1	601ms	+0.0000
Q10	0.7161	0.7161	1	300ms	+0.0000

topK=10

#	Top-1	Avg-3	Chunks	Latence	Δ Top-1
Q1	0.8995	0.8628	4	2061ms	+0.0000
Q2	0.8234	0.8072	3	715ms	+0.0000
Q3	0.8347	0.802	3	1126ms	-0.0003
Q4	0.8586	0.8333	4	1537ms	+0.0000
Q5	0.8019	0.7989	4	611ms	+0.0002
Q6	0.8183	0.8098	4	1230ms	+0.0000
Q7	0.8052	0.7892	3	947ms	+0.0000
Q8	0.7964	0.7811	4	686ms	+0.0000

#	Top-1	Avg-3	Chunks	Latence	Δ Top-1
Q9	0.722	0.7151	2	145ms	+0.0000
Q10	0.7161	0.7134	2	474ms	+0.0000

threshold=0.3

#	Top-1	Avg-3	Chunks	Latence	Δ Top-1
Q1	0.8995	0.8628	5	2287ms	+0.0000
Q2	0.8234	0.8072	5	569ms	+0.0000
Q3	0.8347	0.802	5	1024ms	-0.0003
Q4	0.8586	0.8333	5	1535ms	+0.0000
Q5	0.8019	0.7989	5	638ms	+0.0002
Q6	0.8183	0.8098	5	898ms	+0.0000
Q7	0.8052	0.7892	5	612ms	+0.0000
Q8	0.7964	0.7811	5	920ms	+0.0000
Q9	0.722	0.7084	5	135ms	+0.0000
Q10	0.7161	0.7059	5	380ms	+0.0000

threshold=0.5

#	Top-1	Avg-3	Chunks	Latence	Δ Top-1
Q1	0.8995	0.8628	5	2287ms	+0.0000
Q2	0.8234	0.8072	5	569ms	+0.0000
Q3	0.8347	0.802	5	1024ms	-0.0003
Q4	0.8586	0.8333	5	1535ms	+0.0000
Q5	0.8019	0.7989	5	638ms	+0.0002
Q6	0.8183	0.8098	5	898ms	+0.0000
Q7	0.8052	0.7892	5	612ms	+0.0000
Q8	0.7964	0.7811	5	920ms	+0.0000
Q9	0.722	0.7084	5	103ms	+0.0000
Q10	0.7161	0.7059	5	102ms	+0.0000

Régressions identifiées

Régression 1 — Variante topK=1, Q1

- Question : "Quels sont les motifs de discrimination interdits par l'article L1132-1 du Code ..."
- Type : contexte_incomplet

- Explication : Avec un seul chunk, la réponse perd en complétude. Baseline utilisait ~3-5 chunks pour couvrir la question.

Régression 2 — Variante `topK=1`, Q2

- Question : "Quelles protections existent pour un salarié qui exerce son droit de grève ?"
- Type : `contexte_incomplet`
- Explication : Avec un seul chunk, la réponse perd en complétude. Baseline utilisait ~3-5 chunks pour couvrir la question.

Régression 3 — Variante `topK=1`, Q3

- Question : "Quelles sont les conséquences pour un employeur qui prend une mesure discriminat..."
- Type : `refus_inattendu`
- Explication : Baseline répondait bien (pertinence=4/5, fidélité=4/5), la variante refuse malgré le contexte.

Régression 4 — Variante `topK=1`, Q4

- Question : "Quels sont les niveaux de stabilité définis dans la documentation Node.js ?"
- Type : `contexte_incomplet`
- Explication : Avec un seul chunk, la réponse perd en complétude. Baseline utilisait ~3-5 chunks pour couvrir la question.

Régression 5 — Variante `topK=1`, Q7

- Question : "Un salarié juré peut-il être licencié à cause de ses fonctions de juré ?"
- Type : `contexte_incomplet`
- Explication : Avec un seul chunk, la réponse perd en complétude. Baseline utilisait ~3-5 chunks pour couvrir la question.

Régression 6 — Variante `topK=1`, Q8

- Question : "Est-ce que le module SQLite de Node.js est stable ?"
- Type : `refus_inattendu`
- Explication : Baseline répondait bien (pertinence=4/5, fidélité=5/5), la variante refuse malgré le contexte.

Régression 7 — Variante `threshold=0.3`, Q3

- Question : "Quelles sont les conséquences pour un employeur qui prend une mesure discriminat..."
- Type : `refus_inattendu`
- Explication : Baseline répondait bien (pertinence=4/5, fidélité=4/5), la variante refuse malgré le contexte.

Régression 8 — Variante `threshold=0.3`, Q9

- Question : "Quelle est la capitale de la France ?"
- Type : `hallucination_risque`
- Explication : Question hors corpus (pertinence baseline=1/5) mais variante fournit 5 chunks et le LLM tente de répondre.

Régression 9 — Variante `threshold=0.3`, Q10

- Question : "Comment configurer un serveur Express avec TypeScript ?"
- Type : `hallucination_risque`
- Explication : Question hors corpus (pertinence baseline=1/5) mais variante fournit 5 chunks et le LLM tente de répondre.

Régression 10 — Variante `threshold=0.5`, Q3

- Question : "Quelles sont les conséquences pour un employeur qui prend une mesure discriminat..."
- Type : refus_inattendu
- Explication : Baseline répondait bien (pertinence=4/5, fidélité=4/5), la variante refuse malgré le contexte.

Régression 11 — Variante `threshold=0.5`, Q9

- Question : "Quelle est la capitale de la France ?"
- Type : hallucination_risque
- Explication : Question hors corpus (pertinence baseline=1/5) mais variante fournit 5 chunks et le LLM tente de répondre.

Régression 12 — Variante `threshold=0.5`, Q10

- Question : "Comment configurer un serveur Express avec TypeScript ?"
- Type : hallucination_risque
- Explication : Question hors corpus (pertinence baseline=1/5) mais variante fournit 5 chunks et le LLM tente de répondre.